



MINISTÈRE DE L'ENSEIGNEMENT SUPÉRIEUR
DE LA RECHERCHE SCIENTIFIQUE ET DE L'INNOVATION
UNIVERSITÉ SULTAN MOULAY SLIMANE
**ECOLE NATIONALE DES SCIENCES APPLIQUÉES
DE KHOURIBGA**



Projet de fin d'année (PFA)

Filière : Informatique et Ingénierie des Données



OCP Group - Khouribga site

Présenté par :

CHAIMAE HOURRI

KHADIJA ZOUHAIR

Prédiction de la future courbe HGL pour la détection d'anomalies dans les réseaux de canalisation du transport des phosphates

Sous la supervision :

Pr. Amal OURDOU ENSA Khouribga

Pr. Imad HAFIDI ENSA Khouribga

Mr. Mohammed HOURI OCP Group

Membres du jury :

Pr. El Malki Imane ENSA Khouribga Responsable

Pr. Bouaoultaine Oumaima ENSA Khouribga Examineur

Année Académique : 2025

Sommaire

Dédicace	ii
Remerciements	iii
Résumé	iv
Abstract	v
Table des matières	vii
Table des figures	x
Liste des tableaux	xi
Liste des acronymes	xii
Introduction	1
1 Présentation de l'organisme d'accueil et contexte général du projet	3
2 Présentation du Système et de la HGL	9
3 Collecte et analyse des données	12
4 Solutions pour la gestion des valeurs manquantes	15
5 Prétraitement et préparation des données	18
6 Calcul et visualisation de la HGL (Hydraulic Grade Line)	32
7 Les modèles utilisés	39
8 Interfaces et résultats	43
9 Automatisation de l'analyse HGL avec n8n	47
Conclusion	50
Bibliographie	51
Bibliographie	51

Dédicace

“

À nos chers parents, Nulle dédicace ne saurait exprimer toute l'affection et l'immense gratitude que nous vous portons pour vos sacrifices, vos encouragements et votre soutien inconditionnel tout au long de notre parcours académique. Puisse Dieu vous accorder santé et longue vie afin que nous puissions, à notre tour, vous combler de bonheur.

À nos familles respectives, Merci pour votre présence rassurante et vos encouragements constants, qui ont toujours été un moteur essentiel dans notre cheminement.

*À nos professeurs et encadrants, Pour les efforts que vous avez déployés afin d'assurer et d'améliorer la qualité de notre formation, ainsi que pour vos conseils précieux et votre guidance tout au long de notre cursus. Nous tenons à exprimer une gratitude particulière à : Mr. Mohammed **Houri** et Mr. Alaa **Amgrissi** (OCP), ainsi qu'à Pr. Imad **Hafidi** et Mme Amal **Ourdou** (ENSA Khouribga).*

À nos chers amis et collègues, Pour leur soutien, leurs encouragements et tous les moments agréables partagés. Nous espérons que ces liens d'amitié perdureront à jamais.

ENFIN, À toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce travail, et à tous ceux qui nous sont chers.

Merci du fond du coeur.

”

- CHAIMAE HOURRI

- KHADIJA ZOUHAIR

Remerciements

Avant tout, nous rendons grâce à Dieu, Le Très Miséricordieux, pour la force, la patience et la guidance qu’Il nous a accordées tout au long de ce parcours.

Nous souhaitons exprimer notre profonde gratitude à toutes les personnes qui, de près ou de loin, ont contribué à la réalisation de ce projet de fin d’année.

Nos remerciements vont en particulier à **Pr. Imad Hafidi** et **Mme Amal Ourdou**, nos encadrants académiques, pour leur disponibilité, leurs précieux conseils et leur accompagnement constant, ainsi qu’à **M. Mohammed Hourri**, notre encadrant professionnel au sein du Groupe OCP – Site de Khouribga, pour sa confiance, son suivi attentif et ses orientations pertinentes qui ont grandement enrichi ce travail.

Nous tenons également à remercier l’ensemble du corps professoral de l’**ENSA Khouribga** pour la qualité de l’enseignement dispensé et pour les connaissances qu’il nous a transmises tout au long de notre formation.

Notre reconnaissance va aussi à nos chers parents, pour leurs sacrifices, leur soutien inconditionnel et leur amour indéfectible, véritables sources de motivation et de persévérance dans notre parcours académique et personnel.

Nous n’oublions pas nos collègues, amis et camarades de promotion, pour leur soutien moral, leurs encouragements et les échanges constructifs qui ont accompagné ce stage.

Enfin, nous adressons nos sincères remerciements aux membres du jury pour le temps consacré à l’évaluation de ce travail et pour leurs observations enrichissantes, ainsi qu’à toutes les personnes qui, de près ou de loin, ont apporté leur aide et leur soutien.

Résumé

Le présent rapport de stage porte sur la prédiction, à un horizon de cinq minutes, de la courbe du Hydraulic Grade Line (HGL) afin de détecter des anomalies dans les réseaux de canalisation dédiés au transport des phosphates. Ce travail s'inscrit dans le cadre de notre stage réalisé au sein du Groupe OCP, site de Khouribga.

L'objectif principal est de développer un modèle capable d'anticiper l'évolution de la courbe HGL à partir des données historiques du réseau, dans le but d'identifier rapidement toute anomalie ou dysfonctionnement pouvant compromettre la performance ou la sécurité des opérations de transport. Le projet comprend également la conception d'un assistant simplifié permettant de consulter et d'expliquer les informations relatives au HGL, ainsi que l'automatisation du flux de travail pour l'envoi d'un rapport synthétique à la fin de chaque prédiction.

La méthodologie adoptée inclut la collecte et le prétraitement des données issues du réseau, l'application de techniques d'apprentissage automatique pour modéliser la courbe HGL à court terme, puis l'analyse détaillée des résultats afin de détecter les anomalies. Une automatisation a été mise en place pour générer et transmettre automatiquement un rapport récapitulatif après chaque exécution du modèle. Les performances sont évaluées à l'aide de métriques standards et comparées aux approches existantes.

Les résultats obtenus montrent que le modèle est capable d'anticiper les variations de la courbe HGL sur un horizon de cinq minutes et de détecter efficacement les anomalies, tout en fournissant un outil interactif et un flux automatisé de reporting. Ces apports contribuent à renforcer la maintenance prédictive et à améliorer la fiabilité des réseaux de transport de phosphates.

Mots clés : Courbe HGL, Prédiction à court terme, Assistant HGL, Détection d'anomalies, Automatisation de rapports, Réseaux de canalisation, Transport des phosphates, Apprentissage automatique, Maintenance prédictive.

Abstract

This internship report presents the development of a system for short-term prediction of the Hydraulic Grade Line (HGL) curve—five minutes ahead—in order to detect irregularities in phosphate-transport pipeline networks. The work was carried out during our internship at the OCP Group, Khouribga site.

The main objective is to design a model capable of forecasting the evolution of the HGL curve from historical network data, enabling the prompt identification of any faults or malfunctions that could compromise the performance or safety of phosphate transport. The project also includes the creation of a lightweight assistant for consulting and explaining HGL-related information, as well as the automation of a workflow that generates and sends a concise report at the end of each prediction.

The adopted methodology involves data collection and preprocessing, the application of machine-learning techniques to model short-term HGL behavior, and a detailed analysis of the results to identify potential irregularities. An automated pipeline was implemented to produce a summary report and distribute it after each model execution.

The results show that the proposed model can accurately anticipate HGL variations over the next five minutes and effectively detect irregularities, while providing an interactive assistant and an automated reporting flow. This contributes to enhanced predictive maintenance and improved reliability of phosphate-transport networks.

Keywords : Hydraulic Grade Line (HGL), Irregularity detection, Pipeline networks, Phosphate transport, Machine learning, Predictive maintenance, Workflow automation, Digital assistant.

ملخص:

يركّز هذا التقرير التدريبي على التنبؤ، في أفق خمس دقائق، بمنحنى خط الارتفاع الهيدروليكي (HGL) بهدف الكشف عن الاختلالات في شبكات أنابيب نقل الفوسفات. يندرج هذا العمل ضمن إطار تدريبنا الميداني بموقع مجموعة OCP في خريبكة.

الهدف الأساسي هو تطوير نموذج قادر على توقّع تطور منحنى الـ HGL اعتمادًا على البيانات التاريخية للشبكة، بغية تحديد أي خلل أو أعطال محتملة يمكن أن تؤثر في أداء عمليات النقل أو سلامتها. يشمل المشروع أيضًا تصميم مساعد مبسّط يتيح استشارة وشرح المعلومات المتعلقة بالـ HGL، إلى جانب أتمتة سير العمل لإرسال تقرير موجز في نهاية كل عملية تنبؤ.

تشمل المنهجية جمع البيانات ومعالجتها أوليًا، ثم تطبيق تقنيات التعلم الآلي لنمذجة منحنى الـ HGL على المدى القصير، يلي ذلك تحليل مفصل للنتائج بهدف الكشف عن الاختلالات. كما تم إنشاء أتمتة لتوليد تقرير تلخيصي وإرساله تلقائيًا بعد كل تنفيذ للنموذج.

تم تقييم أداء النظام باستخدام مقاييس معيارية ومقارنته بالأساليب المتاحة.

تُظهر النتائج أن النموذج قادر على توقّع تغيّرات منحنى الـ HGL خلال خمس دقائق والكشف بفعالية عن الاختلالات، مع توفير أداة تفاعلية وتدفق مؤتمت للتقارير، مما يساهم في تعزيز الصيانة التنبؤية وتحسين موثوقية شبكات نقل الفوسفات.

الكلمات المفتاحية: منحنى الارتفاع الهيدروليكي (HGL)، كشف الاختلالات، شبكات الأنابيب، نقل الفوسفات، التعلم الآلي، الصيانة التنبؤية.

Table des matières

Dédicace	ii
Remerciements	iii
Résumé	iv
Abstract	v
Table des matières	vii
Table des figures	x
Liste des tableaux	xi
Liste des acronymes	xii
Introduction	1
1 Présentation de l'organisme d'accueil et contexte général du projet	3
Introduction	3
1.1 Présentation de l'organisme d'accueil	3
1.1.1 Présentation du Groupe OCP	3
1.1.2 Historique	4
1.1.3 Création et évolution du Groupe OCP	4
1.1.4 Activités du Groupe OCP	4
1.1.5 Fiche technique du Groupe OCP	5
1.1.6 Statut juridique et organisation	5
1.1.7 Perspectives de développement	5
1.2 Direction du site de Khouribga	5
1.2.1 Pôle industries de Khouribga (GIK)	5
1.2.2 Organisation du site de Khouribga	5
1.2.3 Catégories de produits	6
1.2.4 Entité Slurry Pipeline	6
1.2.4.1 Présentation et fonctionnement	6
1.2.5 Contexte et problématique du projet	7
1.2.6 Objectifs du projet	7
Conclusion	7
2 Présentation du Système et de la HGL	9

Introduction	9
2.1 Définition de la courbe HGL	9
2.1.1 Objectif	9
2.1.2 Calcul	9
2.1.3 Application à la pipeline OCP (Khouribga – El-Jorf El-Jadida)	10
2.2 Problématiques de la prédiction	10
2.3 Apport du Machine Learning	10
Conclusion	10
3 Collecte et analyse des données	12
Introduction	12
3.1 Sources et structure des datasets	12
3.2 Analyse statistique des données	12
3.2.1 Head_station.csv	12
3.2.2 Terminal_station.csv	13
3.2.3 PMS_ET_SV.csv	13
3.3 Localisation des valeurs manquantes (stations intermédiaires)	13
3.4 Impact sur le calcul de la courbe HGL et la détection d'anomalies	13
Conclusion	14
4 Solutions pour la gestion des valeurs manquantes	15
Introduction	15
4.1 Méthodes d'imputation	15
4.1.1 Imputation par règles physiques	15
4.1.2 Imputation statistique	15
4.1.3 Imputation par Machine Learning	16
4.2 Validation et comparaison des méthodes	16
4.3 Application aux datasets	16
Conclusion	17
5 Prétraitement et préparation des données	18
5.1 Prétraitement des données	18
5.1.1 Nettoyage et formatage	18
5.1.2 Uniformisation des formats	18
5.1.3 Création des datasets pour la modélisation	18
5.2 Prétraitement des données : Station Head Station (HS)	19
5.3 Prétraitement des données : Station Terminal Station (TS)	21
5.4 Prétraitement des données : Stations Pompage Main Station (PMS) et Station de Vanne (SV)	23
5.5 Prédiction des données manquantes avec la station Head	25
5.5.1 Pourquoi prédire les données manquantes ?	25
5.5.2 Pourquoi utiliser la station Head comme référence ?	25
5.5.3 Processus de prédiction	25
5.5.4 Avantages de cette approche	28
5.5.5 Résumé	28
5.6 Fusion des données et synchronisation temporelle	30

6	Calcul et visualisation de la HGL (Hydraulic Grade Line)	32
	Introduction	32
	6.0.1 Données des stations et contraintes géographiques	32
	6.0.2 Méthodologie de calcul	32
	6.0.3 Implémentation Python (calcul & tracé)	33
	6.0.4 Visualisation	37
	6.0.5 Résumé	38
7	Les modèles utilisés	39
	Introduction	39
	7.1 Pourquoi ces modèles sont adaptés à notre cas	40
	Conclusion	42
8	Interfaces et résultats	43
	Introduction	43
	8.1 La prédiction de la courbe HGL	43
	8.2 Vue générale du projet	44
	8.3 Résultats du modèle LSTM	44
	8.4 Résultats du modèle GRU	45
	8.5 Résultats du modèle TCN	45
	8.6 Comparaison des modèles LSTM, GRU et TCN	46
	8.7 Assistant intelligent	46
	Conclusion	46
9	Automatisation de l'analyse HGL avec n8n	47
	Introduction	47
	9.1 - Définition d'un outil d'automatisation	47
	9.2 - Présentation de n8n	48
	9.3 - Utilité dans le projet	49
	Conclusion	49
	Conclusion	50
	Bibliographie	51
	Bibliographie	51

Table des figures

1	Schéma illustrant la méthodologie d'imputation des données dans le réseau HGL . . .	2
1.1	Logo du Groupe OCP	3
1.2	Mine historique de Boujniba – OCP	4
1.3	Mine de Sidi Chennane et unité de transformation Jorf Lasfar	4
1.4	Organisation du site de Khouribga	6
1.5	Échantillons représentatifs des principaux produits	6
1.6	Schéma global du pipeline Khouribga - Jorf Lasfar	7
4.1	Schéma illustrant la méthodologie d'imputation des données dans le réseau HGL . . .	17
5.1	Schéma illustrant Processus de prédiction des données	27
6.1	Exemple de visualisation de la Hydraulic Gradient Line (HGL) superposée au profil du terrain et aux zones de rivières.	37
8.1	Prédiction de la courbe HGL	43
8.2	Vue générale du projet	44
8.3	Prédiction obtenue avec le modèle LSTM	44
8.4	Prédiction obtenue avec le modèle GRU	45
8.5	Prédiction obtenue avec le modèle TCN	45
8.6	Comparaison des prédictions par les modèles LSTM, GRU et TCN	46
8.7	Assistant intelligent du projet	46
9.1	Logo de n8n	47
9.2	Logo de n8n	48
9.3	Schéma illustratif du flux : FastAPI → webhook → Agent IA → Email	49

Liste des tableaux

1.1	Fiche technique synthétique du Groupe OCP	5
5.1	Extrait des données de la station HS	20
5.2	Extrait des données de la station Terminal	22
5.3	Extrait des données des stations PMS et SV	24
7.1	Structure et points forts des modèles	39
7.2	Limites et raisons d'utilisation	39

Liste des acronymes

CSV :

Comma-Separated Values [12](#)

DS :

Dataset [18](#), [19](#), [21](#), [23](#), [31](#)

Glossaire :

Liste des acronymes et termes utilisés [2](#)

HGL :

Hydraulic Grade Line [1](#), [2](#), [9–14](#)

HGL :

Hydraulic Gradient Line [x](#), [18](#), [19](#), [23](#), [25](#), [28](#), [31–33](#), [37](#), [38](#)

HS :

Head Station [viii](#), [xi](#), [19](#), [20](#), [25](#)

ML :

Machine Learning [1](#), [2](#), [9–11](#)

PIT :

Pressure Indicator Transmitter (capteur de pression immergé) [25](#)

PMS :

Pump Monitoring Station [9](#), [10](#), [12–14](#)

PMS :

Pompage Main Station [viii](#), [23–25](#)

Slurry-Pipeline :

Canalisation de transport de pulpe de phosphate [1](#)

SV :

Station de Vanne [viii](#), [23](#), [24](#)

TS :

Terminal Station [viii](#), [21](#), [22](#)

Introduction Générale

Le Maroc, en tant que leader mondial sur le marché des phosphates, a bâti un écosystème industriel où l'innovation logistique est un pilier de la compétitivité. Au cœur de cette stratégie, le Groupe OCP, acteur majeur de l'industrie des engrais phosphatés, a mis en service un ouvrage d'ingénierie remarquable : le [Canalisation de transport de pulpe de phosphate \(Slurry-Pipeline\)](#). Ce système de canalisations transporte la pulpe de phosphate depuis les mines de Khouribga jusqu'aux plateformes de traitement de Jorf Lasfar. L'intégrité et l'efficacité de cette infrastructure sont primordiales pour garantir un flux de production continu, sécurisé et respectueux de l'environnement.

La surveillance de ce réseau repose sur l'analyse de plusieurs paramètres physiques, dont la [Hydraulic Grade Line \(HGL\)](#) (*Hydraulic Grade Line*). La [HGL](#) est un indicateur essentiel qui reflète l'état énergétique du fluide tout au long de son parcours. Toute déviation anormale de sa courbe peut signaler un incident tel qu'une fuite, une obstruction ou une défaillance d'équipement. Une détection tardive de ces anomalies peut entraîner des pertes de production significatives, des coûts de maintenance élevés et des risques environnementaux.

Ce projet de fin d'année, réalisé au sein du Groupe OCP, s'inscrit dans ce contexte de maintenance prédictive. L'objectif initial était d'appliquer des techniques d'apprentissage automatique ([Machine Learning \(ML\)](#)) pour prédire l'évolution de la courbe [HGL](#) et ainsi anticiper les anomalies. Cependant, le déroulement du stage a été marqué par un défi majeur : la disponibilité limitée des données. En effet, seules les mesures de pression aux stations de pompage (**PMS1**, **PMS2**, **VANNE**, **PMS3**, **PMS4**) étaient accessibles de manière fiable et continue. Les données de débit et de densité, pourtant indispensables au calcul précis de la [HGL](#), n'étaient pas disponibles, et l'absence de personnel clé en période de congés a rendu leur collecte impossible à court terme.

Face à cette contrainte, une réorientation du projet s'est avérée nécessaire. Le problème de données, initialement un obstacle, est devenu une partie intégrante de notre mission de recherche. Nous avons dû innover en proposant une solution pour pallier ce manque : prédire les valeurs de débit et de densité à partir des données existantes. Cette démarche a non seulement permis de débloquer le projet principal, mais a également ajouté une valeur considérable à notre travail, en développant une méthodologie robuste pour l'enrichissement de données industrielles.

Ce mémoire détaille donc l'ensemble de ce parcours. Les principaux objectifs de notre étude sont :

- Proposer et valider une méthode pour prédire les données de débit et de densité manquantes.
- Développer un modèle de [ML](#) capable de prédire la courbe [HGL](#) à court terme (cinq minutes).
- Implémenter une solution de visualisation permettant aux opérateurs de suivre les prédictions et de détecter précocement les anomalies.

Pour ce faire, ce rapport s'articulera de la manière suivante : le premier chapitre présentera le cadre général du projet, en décrivant l'organisme d'accueil, le contexte industriel du [Slurry-Pipeline](#), et les

fondements théoriques de la [HGL](#). Le deuxième chapitre sera consacré à la méthodologie adoptée pour la préparation et le traitement des données, en insistant sur notre approche pour la prédiction des variables manquantes. Le troisième chapitre détaillera la phase de modélisation et d'expérimentation des différents algorithmes de [ML](#). Enfin, le quatrième chapitre présentera les résultats obtenus, leur interprétation et la solution de visualisation développée, avant de conclure sur les apports de ce projet et les perspectives futures.

Pour plus de détails sur les acronymes et termes utilisés dans ce mémoire, se référer au [Liste des acronymes et termes utilisés \(Glossaire\)](#).



FIG. 1 : Schéma illustrant la méthodologie d'imputation des données dans le réseau HGL

Chapitre 1

Présentation de l'organisme d'accueil et contexte général du projet

Introduction

Ce premier chapitre est consacré à la présentation du cadre général du projet de fin d'études. Dans un premier temps, nous présenterons l'organisme d'accueil, le Groupe OCP, en mettant en avant son positionnement industriel et son organisation, notamment au niveau du site de Khouribga. Dans un second temps, nous détaillerons le projet lui-même : contexte général, problématique, objectifs, contraintes, cahier des charges, phases de mise en œuvre et planification prévisionnelle.

1.1 Présentation de l'organisme d'accueil

1.1.1 Présentation du Groupe OCP

Le Groupe OCP, constitué de la société mère OCP S.A. ainsi que de ses filiales, occupe une position stratégique en tant que premier exportateur mondial de roche phosphatée et de produits dérivés du phosphate. Son activité couvre toute la chaîne de valeur : extraction, traitement, production d'acide phosphorique et d'engrais phosphatés. La figure 1.1 présente le logo officiel du Groupe OCP.



FIG. 1.1 : Logo du Groupe OCP

1.1.2 Historique

Le Groupe OCP a été fondé le 1er mars 1921 avec l'ouverture de la première mine à Boujniba. Le phosphate extrait a été exporté pour la première fois le 27 juillet 1921. Le groupe s'est progressivement étendu avec de nouveaux sites : Youssoufia, Benguerir, Boucraa-Laâyoune. La figure 1.2 illustre la première mine exploitée par le Groupe OCP à Boujniba.



FIG. 1.2 : Mine historique de Boujniba – OCP

1.1.3 Création et évolution du Groupe OCP

- 1975 : l'Office Chérifien des Phosphates devient officiellement le Groupe OCP.
- 1982-1987 : construction du complexe chimique de Jorf Lasfar.
- 1994-1998 : développement des sites miniers et production d'acide phosphorique purifié.
- 2008 : adoption du statut de société anonyme.
- 2014 : inauguration du plus long pipeline de transport de phosphate au monde.
- 2016-2018 : expansion internationale et croissance du chiffre d'affaires.



FIG. 1.3 : Mine de Sidi Chennane et unité de transformation Jorf Lasfar

1.1.4 Activités du Groupe OCP

1. **Extraction** : récupération des minerais de phosphate, à ciel ouvert ou souterrains.
2. **Traitement** : séparation de la gangue et enrichissement du phosphate.

3. **Transport** : convoyeurs, trains et pipelines vers unités de transformation et ports.
4. **Transformation** : production d'acide phosphorique et d'engrais phosphatés.
5. **Exportation** : expédition vers de nombreux pays.

1.1.5 Fiche technique du Groupe OCP

TAB. 1.1 : Fiche technique synthétique du Groupe OCP

Dénomination sociale	Groupe Office Chérifien des Phosphates
Siège social	2-4 Angle route el-Jadida, boulevard la grande ceinture, Casablanca
Date de création	7 août 1920
Statut juridique	Organisme d'État
Directeur général	Mustapha TARAB
Effectif	19874 agents, dont ingénieurs et équivalents
Capacité de production	35 millions tonnes/an
Centres de production	Khouribga, Benguerir, Youssoufia, Boucrâa/Laâyoune
Centres de transformation	Jorf Lasfar et Safi
Ports d'exportation	Jorf Lasfar, Safi, Casablanca, Laâyoune

1.1.6 Statut juridique et organisation

L'OCP est un établissement public à gestion privée, inscrit au registre du commerce et soumis aux règles fiscales marocaines. Le pouvoir de contrôle est exercé par le conseil d'administration, présidé par SM le roi Mohammed VI ou le Premier ministre en son absence.

1.1.7 Perspectives de développement

Le Groupe vise à accroître sa capacité de production de 35 à 55 millions de tonnes, avec un plan industriel de 115 milliards de dirhams à réaliser d'ici 2020. Le pipeline Khouribga-Jorf Lasfar illustre cette ambition, apportant efficacité et réduction des coûts.

1.2 Direction du site de Khouribga

1.2.1 Pôle industries de Khouribga (GIK)

Le complexe minier se compose de trois zones d'extraction et quatre unités de traitement, avec des installations de séchage et de lavage.

1.2.2 Organisation du site de Khouribga

L'organisation est structurée autour de plusieurs directions et départements, coordonnant ressources humaines, production, gestion des flux, hygiène et sécurité.




FIG. 1.4 : Organisation du site de Khouribga

1.2.3 Catégories de produits

OCP produit : phosphate brut, MAP, DAP, TSP, NPK et acide phosphorique.



FIG. 1.5 : Échantillons représentatifs des principaux produits

1.2.4 Entité Slurry Pipeline

1.2.4.1 Présentation et fonctionnement

Le Slurry Pipeline transporte le phosphate en pulpe depuis les laveries principales vers Jorf Lasfar. Il inclut des réservoirs, pompes en série, vannes régulées par stations HP, et un SCADA pour le contrôle automatisé.



FIG. 1.6 : Schéma global du pipeline Khouribga - Jorf Lasfar

1.2.5 Contexte et problématique du projet

Le transport hydraulique de phosphate par pipeline nécessite un suivi précis des paramètres physiques tels que la pression, la densité et la Hydraulic Grade Line (HGL) à différentes stations. Les variations de ces paramètres peuvent indiquer des dysfonctionnements, des pertes d'efficacité ou des risques d'incident. Cependant, la grande quantité de données collectées, la présence de valeurs manquantes ou erronées, et la complexité des phénomènes hydrauliques rendent l'analyse et la prédiction difficiles.

La problématique centrale du projet est donc de développer des outils robustes pour :

- Prétraiter et nettoyer les données issues du pipeline,
- Détecter automatiquement les anomalies et les situations à risque,
- Prédire l'évolution de la HGL et des paramètres critiques à l'aide de modèles avancés,
- Faciliter la visualisation et l'interprétation des résultats pour la maintenance et l'optimisation du réseau.

1.2.6 Objectifs du projet

Les objectifs principaux du projet sont :

- Mettre en place une chaîne de traitement des données hydrauliques du pipeline (nettoyage, normalisation, séquençage),
- Développer et comparer plusieurs modèles de prédiction (LSTM, GRU, TCN) pour estimer la HGL aux différentes stations,
- Intégrer des méthodes de détection d'anomalies pour anticiper les incidents et améliorer la maintenance,
- Proposer des interfaces de visualisation interactives pour l'analyse des résultats et la prise de décision,
- Fournir des indicateurs de performance et des recommandations pour la maintenance prédictive du réseau.

Conclusion

Le présent chapitre a permis de poser le cadre général du projet de fin d'études, en présentant d'une part le Groupe OCP, son organisation, ses sites d'extraction et de transformation, et d'autre part le projet lui-même, centré sur l'optimisation du transport de phosphate via le Slurry Pipeline de Khouribga à Jorf Lasfar.

Nous avons mis en évidence le contexte et la problématique du projet, soulignant les défis liés à la variabilité des flux, à la maintenance des équipements, à la continuité du transport et au respect des normes environnementales. Les objectifs du projet ont également été clairement définis : analyse des données, détection d'anomalies, prédiction des flux de pulpe, optimisation opérationnelle et conformité environnementale.

Cette introduction fournit une base solide pour les chapitres suivants, où seront détaillés les aspects méthodologiques, la modélisation, les résultats obtenus et les recommandations pour améliorer la performance et la durabilité du transport de phosphate.

Ainsi, ce chapitre établit les fondations nécessaires pour comprendre la démarche adoptée et l'importance stratégique de ce projet dans le cadre des opérations du Groupe OCP.

Chapitre 2

Présentation du Système et de la HGL

Introduction

L'étude et la prédiction de la courbe [HGL](#) jouent un rôle essentiel dans l'ingénierie hydraulique, notamment pour la surveillance et la gestion des pipelines. Dans le contexte de l'OCP, la pipeline reliant Khouribga à El-Jorf El-Jadida est un exemple concret où la [HGL](#) est utilisée pour détecter rapidement des anomalies et assurer un écoulement optimal du produit.

La [HGL](#) est calculée à partir de points stratégiques de la pipeline, tels que la Head Station, [Pump Monitoring Station \(PMS\)](#)¹, la station de vanne, [PMS2](#), [PMS3](#), [PMS4](#) et le terminal. Avec l'augmentation des données disponibles et l'évolution des méthodes d'analyse, le [ML](#) offre une approche prometteuse pour améliorer la précision et la rapidité de la [HGL](#).

Ce chapitre présente les notions fondamentales liées à la [HGL](#), discute des limites des méthodes traditionnelles de prédiction et introduit l'intérêt des techniques d'apprentissage automatique. Ces éléments posent les bases théoriques nécessaires pour aborder les chapitres suivants.

2.1 Définition de la courbe HGL

La [HGL](#), aussi appelée *ligne d'énergie* ou *ligne piézométrique*, est une courbe qui représente la pression et la hauteur du fluide dans une canalisation.

2.1.1 Objectif

La [HGL](#) permet de suivre le **niveau d'énergie** du fluide dans la pipeline et de **détecter des anomalies**, telles que des pertes de pression ou des problèmes de débit, afin de les corriger rapidement.

2.1.2 Calcul

La formule générale de la [HGL](#) est :

$$\text{HGL} = \frac{P}{\rho \cdot g} + z$$

où :

- P : pression du fluide,
- ρ : densité du fluide,
- g : accélération gravitationnelle,
- z : élévation par rapport à un point de référence.

2.1.3 Application à la pipeline OCP (Khouribga – El-Jorf El-Jadida)

Pour tracer la [HGL](#), les points principaux utilisés sont :

1. Head Station,
2. [PMS1](#),
3. Station de vanne,
4. [PMS2](#),
5. [PMS3](#),
6. [PMS4](#),
7. Terminale.

Ces points permettent de surveiller l'écoulement du produit tout au long de la pipeline.

2.2 Problématiques de la prédiction

Les méthodes classiques de calcul et de prédiction de la courbe [HGL](#) reposent sur des modèles analytiques ou des hypothèses simplifiées qui ne tiennent pas toujours compte de la complexité et de la variabilité des systèmes réels. Cette limitation engendre des écarts notables entre les valeurs prédites et les mesures réelles, ce qui rend nécessaire l'utilisation d'approches plus flexibles et adaptées.

2.3 Apport du Machine Learning

Le [ML](#), en exploitant de larges volumes de données de capteurs, permet d'établir des modèles prédictifs capables d'apprendre les relations complexes entre les variables du réseau hydraulique (pression, débit, densité, etc.). Cette approche offre ainsi la possibilité d'améliorer la précision des prédictions à court terme, notamment pour anticiper la courbe [HGL](#) dans les cinq minutes à venir, et de contribuer à une meilleure prise de décision opérationnelle.

Conclusion

Dans ce chapitre, nous avons posé le cadre général de notre travail en présentant la courbe [HGL](#), son importance, les limites des méthodes traditionnelles de prédiction, ainsi que l'intérêt d'introduire le [ML](#) dans ce domaine. Ces éléments constituent la base théorique et contextuelle nécessaire pour aborder, dans les chapitres suivants, la méthodologie adoptée, le traitement des données et l'évaluation des modèles prédictifs proposés.

Dans le chapitre suivant, nous détaillerons la méthodologie adoptée pour la collecte et le traitement des données afin de préparer la mise en œuvre des modèles prédictifs.

Chapitre 3

Collecte et analyse des données

Introduction

Dans ce chapitre, nous présentons les données issues des différentes stations du réseau de transport des phosphates qui constituent la base de notre projet. Nous décrivons tout d'abord les sources de données et leur structuration dans les fichiers [Comma-Separated Values \(CSV\)](#), avant de réaliser une analyse statistique afin de mieux comprendre la nature des variables collectées (pressions, débits, hauteur statique, etc.). Cette étape permet non seulement d'évaluer la richesse et la pertinence des informations disponibles, mais également de mettre en évidence les particularités des jeux de données, notamment la présence de valeurs manquantes, qui représentent un défi majeur pour la modélisation de la courbe [HGL](#) et la détection d'anomalies.

3.1 Sources et structure des datasets

Les données utilisées dans ce projet proviennent des différentes stations du réseau de transport des phosphates : Head, Terminal, [PMS1](#) à [PMS4](#) et VANNE. Chaque station dispose d'un fichier [CSV](#) contenant les mesures collectées (pression, débit, densité, date, etc.).

Les datasets sont structurés avec une colonne temporelle (**Date**) et des colonnes de mesures physiques. Les stations **Head** et **Terminal** disposent de toutes les variables nécessaires au calcul direct de la courbe [HGL](#), tandis que les stations intermédiaires ([PMS](#), **VANNE**) ne disposent que des pressions, nécessitant un calcul complémentaire pour obtenir la [HGL](#).

3.2 Analyse statistique des données

Voici une analyse statistique et un résumé des données pour chaque fichier du dossier **datasets** :

3.2.1 Head_station.csv

- **Variables** : Date, 10-DIT-509, 10-DIT-609, 10-PIT-507, 10-PIT-607, 10-PIT-416, 10-FIT-508.
- **Type de données** : Pression, débit, densité.

- **Fréquence d'échantillonnage** : Toutes les 5 minutes.
- **Exemples de valeurs** : Pression entre ~ 990 et 1600 , débit entre ~ 3500 et 4900 .
- **Utilisation** : Permet de calculer la **HGL** directement grâce à la présence de la hauteur statique et des pressions.

3.2.2 Terminal_station.csv

- **Variables** : Date, 16-PIT-001, 16-FIT-006, 16-DIT-005.
- **Type de données** : Pression, débit, densité.
- **Fréquence d'échantillonnage** : Toutes les 5 minutes.
- **Exemples de valeurs** : Pression entre ~ 1000 et 3000 , débit entre ~ 4200 et 4900 .
- **Utilisation** : Permet de prédire la **HGL** à l'extrémité du réseau.

3.2.3 PMS_ET_SV.csv

- **Variables** : Date, 11-PIT-001, 12-PIT-001, 12-PIT-003, 12-PIT-005, 13-PIT-001, 14-PIT-001, 15-PIT-001.
- **Type de données** : Pression uniquement (valeurs numériques continues).
- **Fréquence d'échantillonnage** : Toutes les 5 minutes.
- **Exemples de valeurs** : Pression entre ~ 1000 et 6000 .
- **Utilisation** : Pour ces stations, la **HGL** est calculée à partir de la pression et de la formule physique :

$$\text{HGL} = \text{Hauteur statique} + \frac{\text{Pression} \times \text{Constante}}{\text{Gravité} \times \text{Masse volumique du liquide}}$$

3.3 Localisation des valeurs manquantes (stations intermédiaires)

Lors de l'analyse des datasets, il a été constaté que les stations intermédiaires (**PMS1**, **PMS2**, **PMS3**, **PMS4**, **VANNE**) ne disposent que des mesures de pression. Les variables essentielles pour le calcul complet de la courbe **HGL**, telles que le débit, la densité ou la hauteur statique, sont absentes ou incomplètes dans ces stations.

En revanche, les stations principales (**Head** et **Terminal**) possèdent des données complètes, ce qui permet un calcul direct et fiable de la **HGL**.

3.4 Impact sur le calcul de la courbe HGL et la détection d'anomalies

L'absence de certaines variables dans les stations intermédiaires rend le calcul de la courbe **HGL** moins précis, car il repose sur des valeurs estimées ou imputées. Cela peut entraîner :

- Une incertitude accrue dans la modélisation de la [HGL](#) sur ces portions du réseau.
- Un risque de fausse détection ou de non-détection d'anomalies, puisque les anomalies peuvent être masquées ou amplifiées par les valeurs imputées.
- Une propagation des erreurs : si les valeurs manquantes sont mal estimées, cela affecte la fiabilité de la [HGL](#) et la performance des modèles de détection.

Pour pallier ce problème, des méthodes d'imputation et de prédiction ont été mises en place afin d'estimer les variables manquantes à partir des données disponibles et des relations physiques du système.

Conclusion

Ce chapitre a permis de détailler les principales caractéristiques des jeux de données utilisés dans notre étude, en mettant en évidence leurs structures, leurs variables et leurs spécificités. L'analyse statistique a montré que, si certaines stations comme **Head** et **Terminal** offrent toutes les informations nécessaires pour le calcul direct de la [HGL](#), les stations intermédiaires ([PMS](#), **VANNE**) présentent des limitations dues à l'absence de certaines mesures. De plus, l'identification des valeurs manquantes souligne l'importance de mettre en place des méthodes robustes de traitement et d'imputation, qui seront étudiées dans le chapitre suivant afin d'assurer la fiabilité des analyses et la performance des modèles prédictifs.

Chapitre 4

Solutions pour la gestion des valeurs manquantes

Introduction

La qualité et la complétude des données sont des éléments critiques pour la modélisation précise de la courbe HGL et la détection d'anomalies dans le réseau de transport des phosphates. Dans ce contexte, plusieurs stations intermédiaires, à savoir PMS1, PMS2, PMS3, PMS4 et VANNE, présentent des valeurs manquantes ou incomplètes, principalement pour les variables débit et densité. Pour pallier cette limitation, différentes méthodes d'imputation ont été mises en œuvre, combinant des approches physiques, statistiques et basées sur le Machine Learning.

4.1 Méthodes d'imputation

Trois catégories principales d'imputation ont été utilisées pour restaurer les données manquantes :

4.1.1 Imputation par règles physiques

Cette approche repose sur les principes physiques du réseau hydraulique :

- Les valeurs manquantes de débit et de densité dans les stations intermédiaires ont été initialisées à partir des mesures disponibles à la Head Station, en supposant une continuité physique du fluide le long de la pipeline.
- Cette méthode fournit une estimation initiale cohérente avec la physique du système, mais elle ne capture pas les variations locales ou les perturbations spécifiques à chaque station.

4.1.2 Imputation statistique

Des méthodes statistiques simples ont été appliquées pour compléter certaines données manquantes :

- Interpolation linéaire ou polynomiale entre points connus pour combler les lacunes dans les séries temporelles.

- Moyennes glissantes calculées sur des fenêtres temporelles afin de stabiliser les estimations en présence de données isolées ou sporadiques.

Cette approche est rapide et simple, mais elle peut introduire des biais si les données présentent des variations rapides ou non linéaires.

4.1.3 Imputation par Machine Learning

La méthode principale repose sur l'apprentissage supervisé à l'aide de modèles de Random Forest :

- Pour chaque station intermédiaire, un modèle est entraîné à partir des données disponibles, incluant la pression mesurée à la station concernée et les variables débit et densité de la Head Station.
- Les modèles apprennent les relations complexes entre ces variables et permettent de prédire de manière fiable les valeurs manquantes de débit et de densité pour chaque station.

Cette approche combine la précision statistique avec une adaptation aux fluctuations locales du réseau, garantissant des estimations réalistes et cohérentes.

4.2 Validation et comparaison des méthodes

L'évaluation des performances des différentes méthodes d'imputation a été effectuée selon plusieurs critères :

- **Comparaison aux valeurs réelles** : lorsque des mesures réelles étaient disponibles, les valeurs imputées ont été comparées aux données observées.
- **Métriques d'erreur** : l'erreur quadratique moyenne (RMSE) et le coefficient de détermination (R^2) ont été utilisés pour quantifier la précision des modèles Machine Learning.
- **Cohérence physique** : les valeurs imputées ont été analysées pour vérifier qu'elles respectaient les contraintes hydrauliques du système (par exemple, le débit ne dépasse pas la capacité maximale de la station, la densité reste dans les limites physiques du fluide).

Les modèles basés sur le Machine Learning ont démontré une supériorité significative par rapport aux méthodes simples :

- Meilleure reproduction des tendances temporelles et des variations locales.
- Réduction des erreurs de prédiction par rapport aux approches statistiques ou aux règles physiques seules.

4.3 Application aux datasets

Les méthodes d'imputation ont été appliquées sur l'ensemble des datasets des stations intermédiaires :

- Chaque fichier enrichi contient désormais la date, la pression mesurée, ainsi que les valeurs prédites de débit et de densité.
- Ces datasets corrigés et enrichis constituent une base fiable pour :
 - La modélisation précise de la courbe HGL,
 - La détection précoce d'anomalies dans le réseau.

Cette démarche garantit non seulement la continuité et la qualité des données, mais elle améliore également la robustesse des modèles prédictifs utilisés pour la surveillance et l'optimisation du réseau de transport des phosphates.




FIG. 4.1 : Schéma illustrant la méthodologie d'imputation des données dans le réseau HGL

Conclusion

La qualité des données étant essentielle pour la modélisation et la surveillance du réseau HGL, l'utilisation combinée des méthodes physiques, statistiques et Machine Learning a permis de restaurer efficacement les valeurs manquantes. L'approche Machine Learning, en particulier, a démontré sa capacité à reproduire fidèlement les tendances locales et à réduire les erreurs, fournissant ainsi un socle solide pour la détection d'anomalies et l'optimisation du réseau.

Chapitre 5

Prétraitement et préparation des données

5.1 Prétraitement des données

La qualité du prétraitement des données est essentielle pour garantir la fiabilité des analyses et des modèles prédictifs. Cette étape comprend plusieurs sous-processus : nettoyage, formatage, uniformisation et création des [Datasets \(DSs\)](#) finaux.

5.1.1 Nettoyage et formatage

Le nettoyage consiste à supprimer ou corriger les valeurs aberrantes, incohérentes ou manquantes dans les fichiers sources. On vérifie la cohérence des colonnes, la présence de doublons et l'intégrité des données.

5.1.2 Uniformisation des formats

Pour faciliter l'analyse et la fusion des données, il est nécessaire d'uniformiser les formats :

- Conversion des dates au format standard YYYY-MM-DD HH:MM:SS.
- Remplacement des virgules par des points pour les décimales (cas des données européennes).
- Harmonisation des noms de colonnes pour toutes les stations.

5.1.3 Création des datasets pour la modélisation

Une fois les données nettoyées et uniformisées, on crée des [DSs](#) spécifiques pour chaque station et pour la modélisation globale :

- Sélection des variables pertinentes (pression, débit, densité, date).
- Fusion des [DSs](#) des différentes stations sur la colonne `Date`.
- Génération de nouveaux fichiers CSV prêts pour l'entraînement des modèles.

Ce prétraitement rigoureux permet d'obtenir des données fiables, cohérentes et prêtes à être utilisées pour la modélisation de la courbe [HGL](#) et la détection d'anomalies.

5.2 Prétraitement des données : Station [HS](#)

Pour la station [HS](#), le prétraitement des données comprend plusieurs étapes visant à nettoyer, uniformiser et préparer le [DS](#) pour la modélisation [HGL](#).

- **Lecture des données :** Les fichiers CSV sont importés avec `pandas`, en prenant soin de gérer le séparateur et l'encodage.
- **Conversion des dates :** La colonne `Date` est convertie au format standard `datetime` pour faciliter les opérations temporelles.
- **Conversion des décimales :** Les colonnes contenant des valeurs numériques exprimées avec des virgules sont converties en points décimaux, puis transformées en type `float`.
- **Calcul des moyennes :**
 - La densité moyenne est calculée à partir des capteurs 10-DIT-509 et 10-DIT-609.
 - La pression moyenne est calculée à partir des capteurs 10-PIT-507 et 10-PIT-607.
- **Renommage et suppression de colonnes :**
 - La colonne 10-FIT-508 est renommée `Flow_HS`.
 - Les colonnes originales utilisées pour calculer les moyennes sont supprimées afin de simplifier le [DS](#).
- **Export final :** Le [DS](#) nettoyé et préparé est enregistré en CSV prêt pour la modélisation.

Code Python de prétraitement :

listings xcolor

```

1 import pandas as pd
2
3 df = pd.read_csv("datasets/Head_station.csv", sep=";", encoding='utf-8-sig')
4 df['Date'] = pd.to_datetime(df['Date'], dayfirst=True)
5
6 cols_to_convert = ['10-DIT-509', '10-DIT-609', '10-PIT-507', '10-PIT-607', '10-PIT-416',
7                    '10-FIT-508']
8 for c in cols_to_convert:
9     df[c] = df[c].astype(str).str.replace(",", ".", regex=False).astype(float)
10
11 df['Density_HS_Average'] = df[['10-DIT-509', '10-DIT-609']].mean(axis=1)
12 df['Pressure_HS_Average'] = df[['10-PIT-507', '10-PIT-607']].mean(axis=1)
13
14 df.rename(columns={'10-FIT-508': 'Flow_HS'}, inplace=True)
15 df = df.drop(columns=['10-DIT-509', '10-DIT-609', '10-PIT-507', '10-PIT-607', '10-PIT-416'], axis=1)
16 df.to_csv("./new_datasets/Head_dataset.csv", index=False)

```

Listing 5.1: Prétraitement des données de la station Head

TAB. 5.1 : Extrait des données de la station [HS](#)

Date	Flow_HS	Density_HS_Average	Pressure_HS_Average
2025-07-01 00:00:00	4242.12	1011.47	1773.27
2025-07-01 00:05:00	4241.75	1011.41	1766.30
2025-07-01 00:10:00	4338.63	1011.35	1780.25
2025-07-01 00:15:00	4374.75	1011.29	1772.71
2025-07-01 00:20:00	4233.67	1011.22	1812.99
2025-07-01 00:25:00	4481.71	1129.17	2395.97
2025-07-01 00:30:00	4093.75	1299.49	2455.88
2025-07-01 00:35:00	4029.68	1300.86	2453.46
2025-07-01 00:40:00	4127.56	1298.49	2455.32

5.3 Prétraitement des données : Station [TS](#)

Pour la station [TS](#), le prétraitement des données comprend les étapes suivantes :

- Importation des données depuis un fichier CSV en gérant l'encodage et le séparateur.
- Conversion de la colonne `Date` au format standard `datetime`.
- Uniformisation des colonnes numériques : remplacement des virgules par des points et conversion en `float`.
- Renommage des colonnes principales :
 - 16-PIT-001 → `Pressure_T`
 - 16-FIT-006 → `Flow_T`
 - 16-DIT-005 → `Density_T`
- Exportation du [DS](#) nettoyé en fichier CSV pour les étapes de modélisation.

Code Python de prétraitement :

```

1 import pandas as pd
2
3 df = pd.read_csv("datasets/Terminal_station.csv", sep=";", encoding='utf-8-sig')
4 df['Date'] = pd.to_datetime(df['Date'], dayfirst=True)
5
6 cols_to_convert = ['16-PIT-001', '16-FIT-006', '16-DIT-005']
7 for c in cols_to_convert:
8     df[c] = df[c].astype(str).str.replace(",", ".", regex=False).astype(float)
9
10 df.rename(columns={'16-PIT-001': 'Pressure_T'}, inplace=True)
11 df.rename(columns={'16-FIT-006': 'Flow_T'}, inplace=True)
12 df.rename(columns={'16-DIT-005': 'Density_T'}, inplace=True)
13
14 df.to_csv("./new_datasets/terminal_dataset.csv", index=False)

```

Listing 5.2: Prétraitement des données de la station Terminal

TAB. 5.2 : Extrait des données de la station Terminal

Date	Pressure_T	Flow_T	Density_T
2025-07-01 00:00:00	2313.47	4297.78	1011.44
2025-07-01 00:05:00	2318.18	4279.48	1007.17
2025-07-01 00:10:00	2326.40	4268.62	1005.78
2025-07-01 00:15:00	2309.05	4229.46	1005.74
2025-07-01 00:20:00	2297.20	4222.04	1006.16
2025-07-01 00:25:00	2294.17	4174.19	1005.44
2025-07-01 00:30:00	2157.31	4581.76	1005.46
2025-07-01 00:35:00	2081.88	4540.12	1005.04
2025-07-01 00:40:00	2089.53	4444.89	1005.03

5.4 Prétraitement des données : Stations PMS et SV

Pour les stations PMS et SV, le prétraitement des données suit les étapes suivantes :

- **Importation des données** : Chargement du fichier CSV contenant les données des deux stations, avec prise en charge de l'encodage et du séparateur.
- **Conversion de la colonne Date** : Transformation de la colonne Date au format `datetime`, afin de faciliter l'analyse temporelle.
- **Uniformisation des formats numériques** : Les colonnes de mesures de pression (PIT) sont converties en flottants après remplacement des virgules par des points.
- **Calcul des moyennes** : - La pression moyenne de la station SV est calculée à partir des trois capteurs 12-PIT-001, 12-PIT-003 et 12-PIT-005, et stockée dans la nouvelle colonne `Presure_SV_Average`.
- **Suppression de colonnes redondantes** : Les capteurs utilisés pour le calcul de la moyenne sont supprimés afin de simplifier le DS.
- **Exportation** : Génération d'un nouveau fichier CSV contenant les données nettoyées et prêtes pour la modélisation HGL.

Code Python de prétraitement :

```
1 import pandas as pd
2
3 df = pd.read_csv("datasets/PMS_ET_SV.csv", sep=";", encoding='utf-8-sig')
4 df['Date'] = pd.to_datetime(df['Date'], dayfirst=True)
5
6 cols_to_convert = ['11-PIT-001', '12-PIT-001', '12-PIT-003', '12-PIT-005',
7                   '13-PIT-001', '14-PIT-001', '15-PIT-001']
8
9 for c in cols_to_convert:
10     df[c] = df[c].astype(str).str.replace(",", ".", regex=False).astype(float)
11
12 df['Presure_SV_Average'] = df[['12-PIT-001', '12-PIT-003', '12-PIT-005']].mean(axis=1)
13
14 df = df.drop(columns=['12-PIT-001', '12-PIT-003', '12-PIT-005'], axis=1)
15
16 df.to_csv("./new_datasets/Cleaned_PMS_SV_station.csv", index=False)
```

Listing 5.3: Prétraitement des données des stations PMS et SV

TAB. 5.3 : Extrait des données des stations PMS et SV

Date	11-PIT-001	13-PIT-001	14-PIT-001	15-PIT-001	Presure SV Average
2025-07-01 00:00:00	1090.80	2924.63	5020.47	2361.50	2056.77
2025-07-01 00:05:00	1114.70	2974.75	5079.66	2404.17	2101.33
2025-07-01 00:10:00	1146.08	2969.77	5081.24	2413.08	2130.12
2025-07-01 00:15:00	1206.38	2992.61	5102.82	2445.61	2176.69
2025-07-01 00:20:00	1202.63	3017.42	5149.34	2514.12	2198.90
2025-07-01 00:25:00	1786.68	3068.45	5191.57	2561.50	2346.28
2025-07-01 00:30:00	2271.82	3622.84	5560.87	2653.10	3110.03
2025-07-01 00:35:00	2267.38	3563.60	5466.44	2576.30	3095.60
2025-07-01 00:40:00	2302.74	3574.39	5480.42	2587.76	3146.20

5.5 Prédiction des données manquantes avec la station Head

Dans le réseau de transport des phosphates, certaines stations intermédiaires ([PMS](#) et vanne) présentent des valeurs manquantes ou incomplètes pour le débit et la densité. Ces données manquantes peuvent nuire à la qualité des analyses et à la modélisation de la [HGL](#). Pour pallier ce problème, nous avons choisi de ****prédire les valeurs manquantes**** à l'aide d'un modèle de machine learning supervisé, en utilisant les informations disponibles.

5.5.1 Pourquoi prédire les données manquantes ?

- Les valeurs manquantes empêchent la construction d'un dataset complet pour la modélisation de la [HGL](#).
- La suppression des lignes contenant des valeurs manquantes peut réduire considérablement la taille des données et introduire un biais.
- La prédiction permet de ****reconstituer un jeu de données complet****, en s'appuyant sur les relations existantes entre les variables des différentes stations.

5.5.2 Pourquoi utiliser la station Head comme référence ?

La station Head ([HS](#)) est la station principale en amont du réseau. Son débit et sa densité influencent directement les mesures des stations situées en aval ([PMS](#) et vanne). En intégrant les mesures de la station Head dans le modèle de prédiction, nous exploitons la corrélation naturelle entre les variables amont et aval :

- Les variations de débit et de densité à Head impactent les stations en aval.
- Les modèles apprennent les relations complexes entre la pression locale des stations intermédiaires et les mesures de Head.
- Cela permet de générer des prédictions plus fiables pour les données manquantes.

5.5.3 Processus de prédiction

Le processus est structuré de la manière suivante :

1. **Chargement des données** : Les datasets prétraités pour la station Head et chaque station PMS/VANNE sont importés sous forme de DataFrame `pandas`. Ces données ont été nettoyées et uniformisées lors de l'étape de prétraitement.
2. **Fusion des datasets** : Pour chaque station intermédiaire, les données sont fusionnées avec celles de la station Head sur la colonne `Date`. Cette fusion permet de synchroniser les mesures temporellement et d'utiliser les informations de Head comme variables explicatives.
3. **Définition des variables** :
 - **Variables explicatives (X)** : Pression locale de la station ([Pressure Indicator Transmitter](#) (capteur de pression immergé) ([PIT](#))), débit et densité de la station Head.

- **Variables cibles (y) :** Débit et densité de la station intermédiaire à prédire.
4. **Séparation train/test :** Le dataset est divisé en ensembles d'entraînement et de test (80% / 20%) pour évaluer la capacité du modèle à généraliser sur de nouvelles données et éviter le surapprentissage.
 5. **Entraînement des modèles :** Pour chaque station et chaque variable cible, un modèle de `RandomForestRegressor` est entraîné. Les modèles apprennent les relations entre la pression locale, les mesures de Head et le débit ou la densité à prédire.
 6. **Prédiction et sauvegarde :** Les modèles génèrent des prédictions pour toutes les lignes du dataset. Les résultats sont sauvegardés dans un nouveau fichier CSV contenant : Date, Pression locale, Débit prédit, Densité prédite.

Processus de prédiction




FIG. 5.1 : Schéma illustrant Processus de prédiction des données

5.5.4 Avantages de cette approche

- Permet de reconstruire un dataset complet pour chaque station intermédiaire, nécessaire pour la modélisation de la [HGL](#).
- Exploite efficacement les relations entre la station Head et les stations intermédiaires.
- Les modèles supervisés, tels que la `RandomForestRegressor`, sont robustes face aux données non linéaires et bruitées.
- Facilite l'analyse ultérieure et la détection d'anomalies dans le réseau de transport.

5.5.5 Résumé

En résumé, cette méthode de prédiction :

- Conserve la cohérence temporelle entre toutes les stations.
- Utilise la station Head comme référence pour améliorer la précision des prédictions.
- Génère des données fiables pour les stations PMS et VANNE, complétant ainsi les informations manquantes pour la modélisation de la [HGL](#).

Code Python de prédiction :

```

1 import pandas as pd
2 from sklearn.model_selection import train_test_split
3 from sklearn.ensemble import RandomForestRegressor
4
5 # Load Head station data
6 head_df = pd.read_csv('./new_datasets/head_dataset.csv')
7
8 # List of PMS/VANNE stations and their pressure columns
9 stations = {
10     'PMS1': '11-PIT-001',
11     'PMS2': '13-PIT-001',
12     'PMS3': '14-PIT-001',
13     'PMS4': '15-PIT-001',
14     'VANNE': 'Pressure_SV_Average'
15 }
16
17 for station, pressure_col in stations.items():
18     # Load PMS/VANNE station data
19     pms_df = pd.read_csv(f'./new_datasets/{station}_dataset.csv')
20     # Merge with Head station on Date
21     merged = pd.merge(pms_df, head_df, on='Date', suffixes=(f'_{station}', '_Head'))
22     # Features: Pressure at PMS/VANNE + Flow and Density at Head
23     X = merged[['Pressure_{station}', 'Flow_HS', 'Density_HS_Average']]
24     # Targets: Flow and Density at PMS/VANNE
25     y_flow = merged[f'Flow_{station}']
26     y_density = merged[f'Density_{station}']
27     # Train/test split
28     X_train_f, X_test_f, y_train_f, y_test_f = train_test_split(X, y_flow, test_size=0.2,
29                                                                     random_state=42)

```

```
29 X_train_d, X_test_d, y_train_d, y_test_d = train_test_split(X, y_density, test_size
    =0.2, random_state=42)
30 # Train models
31 model_flow = RandomForestRegressor(n_estimators=100, random_state=42)
32 model_flow.fit(X_train_f, y_train_f)
33 model_density = RandomForestRegressor(n_estimators=100, random_state=42)
34 model_density.fit(X_train_d, y_train_d)
35 # Predict for all rows
36 merged[f'Flow_{station}_pred'] = model_flow.predict(X)
37 merged[f'Density_{station}_pred'] = model_density.predict(X)
38 # Save only Date, Pressure, Flow_pred, Density_pred for the station
39 output = merged[['Date', f'Pressure_{station}', f'Flow_{station}_pred', f'Density_{
    station}_pred']]
40 output.to_csv(f'./new_dataset/updated_{station}_pred.csv', index=False)
41 print(f' {station} predictions saved (sans Head station).')
42
43 print(' All PMS/VANNE stations processed with Head station data.')
```

Listing 5.4: Prédiction des données manquantes pour les stations PMS et VANNE

5.6 Fusion des données et synchronisation temporelle

Afin d’assurer une analyse cohérente et globale du réseau de transport des phosphates, il est indispensable de regrouper les données de toutes les stations dans un seul tableau synchronisé. Chaque station (*Head*, *PMS1*, *Vanne*, *PMS2*, *PMS3*, *PMS4*, *Terminal*) enregistre ses propres mesures à différents instants.

La fusion des datasets sur la colonne “Date” permet d’aligner toutes les informations temporelles, garantissant que les valeurs utilisées pour le calcul de la HGL et l’analyse du réseau correspondent au même moment.

Cette étape est essentielle pour visualiser l’évolution de la HGL sur l’ensemble du réseau, détecter des anomalies, et faciliter la modélisation prédictive.

Le résultat est un `DataFrame` complet, où chaque ligne représente une date et regroupe l’ensemble des mesures de toutes les stations, offrant ainsi une base solide pour les analyses hydrauliques et statistiques.

Le script suivant permet de regrouper les données issues de toutes les stations (*Head*, *PMS1*, *Vanne*, *PMS2*, *PMS3*, *PMS4*, *Terminal*) dans un seul `DataFrame`. Cette étape est indispensable pour **obtenir une base consolidée, synchronisée temporellement et prête pour l’analyse de la**

HGL. :

```

1 import pandas as pd
2 from functools import reduce
3
4 stations = ['Head', 'PMS1', 'Vanne', 'PMS2', 'PMS3', 'PMS4', 'Terminal']
5
6 dfs = {}
7
8 # Load updated datasets
9 for station in stations:
10     if station in ['Head', 'Terminal']:
11         dfs[station] = pd.read_csv(f'./new_datasets/{station}_dataset.csv', sep=',',
12                                   decimal='.')
13     else:
14         dfs[station] = pd.read_csv(f'./new_dataset/updated_{station}_pred.csv', sep=',',
15                                   decimal='.')
16
17 # Merge all datasets on 'Date'
18 dfs_list = [dfs[station] for station in stations]
19 merged_df = reduce(lambda left, right: pd.merge(left, right, on='Date', how='outer'),
20                   dfs_list)
21
22 # Save merged dataset
23 merged_df.to_csv('./new_dataset/Merged_All_Stations_updated.csv',
24                 index=False, sep=',', decimal='.')
25 print(f" Merged dataset created: {merged_df.shape[0]} rows, {merged_df.shape[1]} columns"
26       )

```

Listing 5.5: Fusion des datasets de toutes les stations

Conclusion

Le prétraitement des données constitue une étape fondamentale dans notre méthodologie. En assurant le nettoyage, l'uniformisation et la structuration des [DSs](#), nous avons pu éliminer les incohérences et garantir l'intégrité des mesures collectées.

Grâce à ces opérations, les datasets finaux présentent une cohérence temporelle et une homogénéité de format, rendant possible la fusion des différentes stations et la modélisation fiable de la [HGL](#).

Ainsi, ce travail prépare un socle de données robuste et exploitable, indispensable pour la suite des analyses hydrauliques et la mise en place de modèles prédictifs performants.

Chapitre 6

Calcul et visualisation de la HGL (Hydraulic Grade Line)

Introduction

L'objectif de cette étape est de calculer et de représenter graphiquement la [HGL](#) du pipeline reliant les différentes stations du réseau de transport des phosphates. La [HGL](#) traduit la répartition des pressions hydrauliques le long de l'ouvrage, ce qui permet d'analyser les conditions d'écoulement et d'identifier d'éventuelles zones critiques.

6.0.1 Données des stations et contraintes géographiques

Chaque station (*Head*, *PMS1*, *Vanne*, *PMS2*, *PMS3*, *PMS4*, *Terminal*) est caractérisée par :

- son élévation géographique z (en mètres),
- sa position le long du pipeline (abscisse curviligne, en kilomètres),
- ses mesures de pression P et de densité ρ extraites du `DataFrame` fusionné.

Afin de modéliser de manière réaliste le profil hydraulique, les franchissements de rivières sont pris en compte : le tracé de la [HGL](#) doit rester au-dessus du niveau d'eau local pour garantir la continuité hydraulique et éviter toute contre-pression défavorable.

6.0.2 Méthodologie de calcul

Le calcul de la [HGL](#) s'appuie sur la relation piézométrique classique :

$$\text{HGL} = \frac{P}{\rho g} + z$$

où :

- P est la pression mesurée (en Pascal),
- ρ est la densité du fluide (kg/m^3),
- g est l'accélération de la pesanteur ($9,81 \text{ m/s}^2$),

- z est l'élévation topographique de la station (m).

La procédure suivie est la suivante :

1. **Chargement des données** : import du DataFrame fusionné contenant pressions et densités de toutes les stations (alignées temporellement).
2. **Normalisation des unités** : conversion cohérente des pressions en Pascal selon l'unité source (kPa, bar, ...).
3. **Calcul de la HGL** à chaque station et à chaque date : application de la formule $\frac{P}{\rho g} + z$.
4. **Application des contraintes « rivières »** : pour chaque portion franchissant une rivière, la HGL est contrainte à rester au-dessus du niveau d'eau.

6.0.3 Implémentation Python (calcul & tracé)

Le code suivant calcule la HGL pour chaque station, applique les contraintes liées aux rivières et génère une visualisation instantanée (*snapshot*). Les figures sont sauvegardées dans le dossier **figures/** (à créer si nécessaire) et pourront être incluses dans le rapport.

```

1 import os
2 import numpy as np
3 import pandas as pd
4 import matplotlib.pyplot as plt
5
6 # -----
7 # 1) Constantes et paramètres
8 # -----
9 g = 9.81 # m/s^2
10 P_UNIT = "kPa" # unité des colonnes de pression dans le dataset: "kPa", "bar" ou "Pa"
11 P_CONV = {"Pa": 1.0, "kPa": 1e3, "bar": 1e5}[P_UNIT]
12
13 # Ordre logique des stations le long du pipeline
14 stations = {
15     "Head": {"elevation_m": 650, "distance_km": 0},
16     "PMS1": {"elevation_m": 680, "distance_km": 45},
17     "VANNE": {"elevation_m": 515, "distance_km": 68},
18     "PMS2": {"elevation_m": 360, "distance_km": 101},
19     "PMS3": {"elevation_m": 110, "distance_km": 130},
20     "PMS4": {"elevation_m": 143, "distance_km": 162},
21     "Terminal": {"elevation_m": 60, "distance_km": 187}
22 }
23
24 # Franchissements de rivières (exemple)
25 river_crossings = [
26     {"start_km": 60, "end_km": 70, "water_elev_m": 520}, # proche de VANNE
27     {"start_km": 140, "end_km": 150, "water_elev_m": 120}, # entre PMS3 et PMS4
28 ]
29
30 # -----
31 # 2) Chargement et préparation des données
32 # -----
33 df_path = "./new_dataset/Merged_All_Stations_updated.csv"
34 merged_df = pd.read_csv(df_path, sep=";", decimal=".", engine="python")

```

```

35
36 # Colonnes (noms attendus dans le dataset fusionné)
37 pressure_cols = {
38     "Head": "Pressure_HS_Average",
39     "PMS1": "Pressure_PMS1",
40     "VANNE": "Pressure_VANNE",
41     "PMS2": "Pressure_PMS2",
42     "PMS3": "Pressure_PMS3",
43     "PMS4": "Pressure_PMS4",
44     "Terminal": "Pressure_T",
45 }
46 density_cols = {
47     "Head": "Density_HS_Average",
48     "PMS1": "Density_PMS1",
49     "VANNE": "Density_VANNE",
50     "PMS2": "Density_PMS2",
51     "PMS3": "Density_PMS3",
52     "PMS4": "Density_PMS4",
53     "Terminal": "Density_T",
54 }
55
56 # Conversion sûre en numérique
57 for col in list(pressure_cols.values()) + list(density_cols.values()):
58     if col in merged_df.columns:
59         merged_df[col] = pd.to_numeric(merged_df[col], errors="coerce")
60
61 # -----
62 # 3) Fonctions de calcul HGL et contrainte "rivière"
63 # -----
64 def river_constrained_head(head_value, distance_km):
65     """
66     Si la station est dans une zone de rivière, force la HGL à rester
67     au-dessus du niveau d'eau local.
68     """
69     if np.isnan(head_value):
70         return np.nan
71     for r in river_crossings:
72         if r["start_km"] <= distance_km <= r["end_km"]:
73             return max(head_value, r["water_elev_m"])
74     return head_value
75
76 def compute_hgl_row(row, st_name):
77     """
78     Calcule HGL = P/(rho*g) + z pour une station 'st_name' et une ligne 'row'.
79     """
80     p_col = pressure_cols[st_name]
81     d_col = density_cols[st_name]
82
83     P = row.get(p_col, np.nan) # P (kPa/bar/Pa selon P_UNIT)
84     rho = row.get(d_col, np.nan) # kg/m^3
85     if pd.isna(P) or pd.isna(rho):
86         return np.nan
87
88     # Conversion pression vers Pascal
89     P_pa = float(P) * P_CONV

```

```

90
91     # Elévation de la station
92     z = stations[st_name]["elevation_m"]
93
94     # Hauteur piézométrique
95     hgl = P_pa / (rho * g) + z
96
97     # Application de la contrainte "rivière"
98     dist = stations[st_name]["distance_km"]
99     return river_constrained_head(hgl, dist)
100
101 # -----
102 # 4) Calcul HGL pour toutes les stations
103 # -----
104 for st in stations.keys():
105     merged_df[f"HGL_{st}"] = merged_df.apply(lambda r: compute_hgl_row(r, st), axis=1)
106
107 # -----
108 # 5) Visualisation instantanée (snapshot)
109 # -----
110 os.makedirs("figures", exist_ok=True)
111
112 # Choix d'une date: dernière ligne disponible avec HGL valides
113 hgl_cols = [f"HGL_{s}" for s in stations.keys()]
114 valid_df = merged_df.dropna(subset=hgl_cols, how="any")
115 if not valid_df.empty:
116     snapshot = valid_df.iloc[-1]
117 else:
118     # A défaut, on prend la dernière ligne et on tracera uniquement les points valides
119     snapshot = merged_df.iloc[-1]
120
121 # Profil du terrain (interpolation douce)
122 station_names = list(stations.keys())
123 distances = np.array([stations[s]["distance_km"] for s in station_names])
124 elevations = np.array([stations[s]["elevation_m"] for s in station_names])
125 xx = np.linspace(distances.min(), distances.max(), 600)
126 zz = np.interp(xx, distances, elevations)
127
128 # HGL au snapshot
129 hgl_vals = [snapshot.get(f"HGL_{s}", np.nan) for s in station_names]
130
131 plt.figure(figsize=(12, 6))
132 # Sol
133 plt.fill_between(xx, 0, zz, alpha=0.6, label="Profil du sol")
134 plt.plot(xx, zz, linewidth=1.5)
135
136 # Rivières
137 for i, r in enumerate(river_crossings):
138     rx = np.linspace(r["start_km"], r["end_km"], 50)
139     rz = np.interp(rx, xx, zz)
140     plt.fill_between(rx, rz, r["water_elev_m"], alpha=0.5, label="Rivière" if i == 0 else
141                     None)
142
143 # Tracé HGL (segments entre stations valides)
144 valid_pts = [(d, h) for d, h in zip(distances, hgl_vals) if not np.isnan(h)]

```

```

144 if len(valid_pts) >= 2:
145     d_valid, h_valid = zip(*valid_pts)
146     dd = np.linspace(min(d_valid), max(d_valid), 400)
147     hh = np.interp(dd, d_valid, h_valid)
148     # maintien au-dessus du niveau d'eau sur les portées de rivière
149     for r in river_crossings:
150         mask = (dd >= r["start_km"]) & (dd <= r["end_km"])
151         hh[mask] = np.maximum(hh[mask], r["water_elev_m"])
152     plt.plot(dd, hh, linewidth=2.5, label="HGL")
153
154 # Marqueurs de stations
155 for s, d, z, h in zip(station_names, distances, elevations, hgl_vals):
156     plt.plot([d, d], [z, z+20], "--", alpha=0.4) # repère vertical
157     if not np.isnan(h):
158         plt.plot(d, h, "o", markersize=6)
159         plt.text(d, h + 15, s, ha="center")
160
161 plt.xlabel("Distance (km)")
162 plt.ylabel("Hauteur (m)")
163 plt.title(f"HGL vs profil du pipeline - Date: {snapshot.get('Date', 'N/A')}")
164 plt.grid(True, alpha=0.3)
165 plt.legend()
166 plt.tight_layout()
167 plt.savefig("figures/hgl_snapshot.png", dpi=300, bbox_inches="tight")
168 plt.close()
169
170 print("Figure sauvegardée: figures/hgl_snapshot.png")

```

Listing 6.1: Calcul et visualisation de la HGL

6.0.4 Visualisation

Les visualisations superposent le *profil du sol*, les *zones de rivières* et la *courbe de HGL*. Le script ci-dessus enregistre un *snapshot* représentatif que l'on peut inclure comme suit :




FIG. 6.1 : Exemple de visualisation de la HGL superposée au profil du terrain et aux zones de rivières.

6.0.5 Résumé

En synthèse, cette étape :

- calcule la hauteur piézométrique à chaque station via $\frac{P}{\rho g} + z$, à partir des pressions et densités issues du `DataFrame` fusionné ;
- applique les contraintes géographiques aux franchissements de rivières pour garantir une [HGL](#) physiquement cohérente ;
- produit une visualisation claire du profil hydraulique du pipeline, facilitant la détection des zones critiques (pertes de charge anormales, risques de sous-pression, etc.).

Conclusion

La fusion des données issues des différentes stations constitue une étape clé pour garantir la cohérence temporelle et la fiabilité des analyses. Elle permet de disposer d'une vision unifiée du réseau, facilitant la détection d'anomalies et l'élaboration de modèles prédictifs performants.

Chapitre 7

Les modèles utilisés

Introduction

Dans cette étude, nous avons cherché à prédire la Hauteur Géométrique de Liquide (HGL) le long d'un réseau de transport de phosphates. Étant donné que les HGL dépendent à la fois du temps et des caractéristiques des différentes stations (débit, densité, pression), il est essentiel d'utiliser des modèles capables de capturer les dépendances temporelles et les interactions multivariées.

Pour cela, nous avons choisi d'explorer trois modèles de deep learning pour séries temporelles : LSTM, GRU et TCN. Chacun de ces modèles présente des avantages spécifiques pour le traitement de données séquentielles et multivariées.

Nous avons choisi trois modèles pour prédire la HGL : LSTM, GRU et TCN. Les tableaux ci-dessous présentent leurs caractéristiques de manière concise.

TAB. 7.1 : Structure et points forts des modèles

Modèle	Structure	Points forts
LSTM	RNN avec cellules mémoire et portes	Capture des dépendances à long terme, robuste aux séries temporelles
GRU	Variante simplifiée de LSTM, 2 portes	Moins complexe, convergence rapide
TCN	Convolutions dilatées causales + résidus	Parallélisable, stable, capture dépendances longues rapidement

TAB. 7.2 : Limites et raisons d'utilisation

Modèle	Limites	Pourquoi utilisé
LSTM	Lent à entraîner, paramétrage sensible	Capture l'influence des stations et variations de débit/densité/pression
GRU	Moins performant pour séquences très longues	Bon compromis vitesse/performance pour la dynamique du fluide
TCN	Moins intuitif, réglage kernel/dilation	Adapté aux séries multivariées, effet stations pris en compte rapidement

7.1 Pourquoi ces modèles sont adaptés à notre cas

La prédiction de la HGL (Hauteur de Ligne de Gravité) dans un réseau de transport de phosphates présente plusieurs particularités qui justifient le choix de modèles séquentiels comme LSTM, GRU et TCN :

- **Données multivariées et temporelles** : Le HGL dépend simultanément de multiples variables (pression, débit, densité) mesurées à différentes stations et à différents instants. Pour capturer ces relations temporelles et multivariées, il est nécessaire d'utiliser des modèles capables de traiter des séquences complexes, tels que LSTM, GRU ou TCN.
- **Effets cumulés des stations et des rivières** : La HGL à une station donnée est influencée non seulement par les conditions locales, mais aussi par toutes les stations en amont et les passages sur les rivières qui provoquent des élévations ponctuelles du niveau. LSTM, GRU et TCN sont capables de modéliser ces dépendances complexes sur de longues séquences.
- **Prévision continue le long du pipeline** : L'objectif est de reconstruire un profil HGL sur toute la longueur du pipeline (187 km). Les TCN sont particulièrement adaptés car ils permettent un traitement parallèle et efficace des séquences, ce qui facilite la génération de profils continus rapidement.
- **Robustesse aux anomalies et au bruit** : Les mesures de pression et de débit sont souvent bruyantes ou partielles. Les LSTM et GRU offrent des capacités de "filtrage naturel" grâce à leurs cellules mémoire, qui intègrent l'information pertinente et atténuent l'effet des fluctuations ponctuelles. Les TCN, grâce à leur architecture à convolutions dilatées et résidus, sont également stables face au bruit.

Ainsi, ces modèles combinent la capacité à capturer des dépendances temporelles longues, la gestion de séquences multivariées et la robustesse face au bruit, ce qui les rend particulièrement adaptés à la prédiction du HGL dans un réseau de transport de phosphates.

```
1 def build_lstm_model(input_shape, output_size):
2     model = Sequential([
3         LSTM(64, activation='tanh', return_sequences=True, input_shape=
4             input_shape),
5         Dropout(0.2),
6         LSTM(64, activation='tanh'),
7         Dense(32, activation='relu'),
8         Dense(output_size)
9     ])
10    model.compile(optimizer='adam', loss='mse')
11    return model
12
13 def build_gru_model(input_shape, output_size):
14     model = Sequential([
15         GRU(64, activation='tanh', return_sequences=True, input_shape=
16             input_shape),
17         Dropout(0.2),
18         GRU(64, activation='tanh'),
19         Dense(32, activation='relu'),
20         Dense(output_size)
21     ])
22    model.compile(optimizer='adam', loss='mse')
23    return model
24
25 def build_tcn_model(input_shape, output_size):
26     model = Sequential([
27         TCN(nb_filters=64, kernel_size=3, dilations=[1, 2, 4, 8], dropout_rate
28             =0.2, input_shape=input_shape),
29         Dense(32, activation='relu'),
30         Dense(output_size)
31     ])
32    model.compile(optimizer='adam', loss='mse')
33    return model
```

Listing 7.1: Définition des modèles LSTM, GRU et TCN

Conclusion

Dans ce travail, nous avons étudié la prédiction de la Hauteur Géométrique de Liquide (HGL) le long d'un réseau de transport de phosphates. Le choix des modèles LSTM, GRU et TCN s'est révélé pertinent compte tenu des spécificités des données : multivariées, temporelles, sujettes au bruit et influencées par des effets cumulés le long du pipeline et des passages de rivières.

Les modèles LSTM et GRU permettent de capturer efficacement les dépendances temporelles et de gérer le bruit grâce à leurs cellules mémoire. Le TCN, quant à lui, offre une approche parallélisable et rapide, particulièrement adaptée pour générer des profils continus sur de longues séquences.

Enfin, l'utilisation de ces modèles a permis de reconstruire des profils HGL cohérents, même lorsque certaines mesures intermédiaires étaient manquantes ou prédites. Cette approche constitue une base solide pour le monitoring et la prévision du niveau de liquide dans le réseau, et peut être étendue à des analyses prédictives ou à la détection d'anomalies dans des systèmes similaires.

Chapitre 8

Interfaces et résultats

Introduction

Dans ce chapitre, nous présentons la page principale du projet et ses différentes fonctionnalités, ainsi que les résultats obtenus lors de la prédiction de la courbe HGL. Nous allons successivement décrire la page de prédiction, l’affichage général, puis les résultats issus des modèles LSTM, GRU et TCN, avant de comparer leurs performances.

8.1 La prédiction de la courbe HGL

La première fonctionnalité permet de charger les données d’entrée et de lancer la prédiction de la courbe HGL. L’utilisateur peut visualiser la courbe prédite et vérifier la correspondance avec les données réelles.




FIG. 8.1 : Prédiction de la courbe HGL

8.2 Vue générale du projet

La vue générale regroupe les principales composantes du projet et donne accès à la prédiction, à la comparaison des modèles et aux résultats finaux. Elle constitue le point central de navigation pour l'utilisateur.




FIG. 8.2 : Vue générale du projet

8.3 Résultats du modèle LSTM

Le modèle LSTM met en évidence sa capacité à capturer les dépendances temporelles des données. La prédiction montre une courbe HGL proche de la réalité, ce qui illustre la robustesse de ce modèle pour les séries temporelles.




FIG. 8.3 : Prédiction obtenue avec le modèle LSTM

8.4 Résultats du modèle GRU

Le modèle GRU, plus léger que le LSTM, fournit également une prédiction de qualité. Il permet d'obtenir des résultats comparables tout en réduisant le temps d'entraînement et la complexité du calcul.




FIG. 8.4 : Prédiction obtenue avec le modèle GRU

8.5 Résultats du modèle TCN

Le modèle TCN repose sur des convolutions temporelles causales. Il se distingue par sa rapidité et son efficacité dans le traitement de longues séquences, ce qui en fait une alternative intéressante aux modèles récurrents.




FIG. 8.5 : Prédiction obtenue avec le modèle TCN

8.6 Comparaison des modèles LSTM, GRU et TCN

La comparaison des résultats obtenus avec les trois modèles met en évidence leurs performances respectives. Cette visualisation commune permet d'identifier rapidement les forces et limites de chaque approche, et d'orienter le choix du modèle le plus adapté.




FIG. 8.6 : Comparaison des prédictions par les modèles LSTM, GRU et TCN

8.7 Assistant intelligent

Le projet intègre également un assistant intelligent sous forme de chatbot, conçu pour guider l'utilisateur, répondre à ses questions et simplifier l'interaction avec la page de prédiction.




FIG. 8.7 : Assistant intelligent du projet

Conclusion

Les résultats obtenus montrent que les modèles de deep learning tels que LSTM, GRU et TCN permettent de prédire efficacement la courbe HGL. Bien que leurs performances varient selon les caractéristiques des données, leur comparaison permet d'identifier l'approche la plus adaptée afin d'améliorer la précision et la robustesse des prédictions.

Chapitre 9

Automatisation de l'analyse HGL avec n8n

Introduction

Dans cette section, nous présentons le contexte général du projet, ses objectifs ainsi que la méthodologie adoptée. Un outil d'automatisation comme **n8n** permet de simplifier et d'optimiser l'intégration entre différentes applications grâce à des flux automatisés (workflows). Cela offre un gain de temps et réduit les erreurs humaines en automatisant des tâches répétitives.

9.1 - Définition d'un outil d'automatisation

Un outil d'automatisation est une plateforme logicielle qui permet de relier plusieurs services ou applications, afin de créer des processus automatisés sans nécessiter de développement complexe. Il facilite l'intégration de services comme des API, des bases de données, des emails, ou des agents intelligents.




FIG. 9.1 : Logo de n8n

9.2 - Présentation de n8n

n8n est un outil d'automatisation open-source qui offre une interface visuelle intuitive. Il permet de créer des workflows en connectant différents nœuds représentant des services (APIs, bases de données, webhooks, etc.). L'avantage de n8n réside dans sa flexibilité et sa capacité à s'intégrer avec de nombreux services tiers.




FIG. 9.2 : Logo de n8n

9.3 - Utilité dans le projet

Dans notre projet, n8n a été utilisé comme orchestrateur pour automatiser les échanges entre **FastAPI**, un **agent IA** et l'envoi automatique d'emails. Ainsi, un webhook reçoit la requête via FastAPI, l'agent IA traite la donnée, puis n8n déclenche l'action d'envoi d'email au destinataire final.




FIG. 9.3 : Schéma illustratif du flux : FastAPI → webhook → Agent IA → Email

Conclusion

L'utilisation de n8n dans le projet a permis de démontrer l'efficacité des outils d'automatisation dans la création de processus intelligents et flexibles. Grâce à cette intégration, nous avons pu réduire la complexité technique et améliorer la rapidité d'exécution des tâches.

Conclusion Générale

Dans ce projet, nous avons abordé la problématique de la prédiction de la Hauteur de Ligne Piézométrique (HGL) à partir de données industrielles de pression, de débit et de densité relevées dans plusieurs stations sur une période donnée. L'objectif principal était d'exploiter les techniques avancées de deep learning appliquées aux séries temporelles afin d'anticiper les variations du HGL et ainsi contribuer à une meilleure compréhension et gestion du réseau étudié.

Pour atteindre cet objectif, nous avons mis en oeuvre différents modèles de réseaux de neurones :

- Les CNN, capables d'extraire efficacement des motifs locaux dans les séquences.
- Les RNN (LSTM et GRU), particulièrement adaptés au traitement des dépendances temporelles longues et complexes.
- Les TCN (Temporal Convolutional Networks), qui offrent une alternative prometteuse grâce à leur parallélisation et leur capacité à capturer de longues dépendances tout en évitant certains inconvénients des RNN.

Les résultats obtenus montrent que ces modèles sont pertinents pour la prédiction du HGL. Chacun présente des avantages spécifiques :

- Les LSTM s'illustrent par leur robustesse face aux longues séquences.
- Les GRU se démarquent par leur rapidité et une complexité réduite.
- Les TCN permettent une meilleure évolutivité et une exploitation efficace des données parallélisées.

En complément de cet axe principal, nous avons également travaillé sur un chatbot visant à rendre l'interaction avec le système plus intuitive et accessible. L'intégration d'un tel outil ouvre la voie à des solutions plus intelligentes et interactives. Cependant, la version actuelle reste une première itération. Nous envisageons d'améliorer considérablement le chatbot grâce à des techniques avancées telles que le RAG (Retrieval-Augmented Generation), ce qui permettrait de combiner la puissance des modèles génératifs avec des bases de connaissances pertinentes et contextualisées.

Ainsi, ce projet constitue une étape importante vers une meilleure exploitation des données industrielles et une intégration intelligente de l'IA dans le suivi du HGL. Toutefois, il ne s'agit pas d'une version finale : des améliorations, tant au niveau des modèles de prédiction que des outils interactifs, sont prévues afin d'aboutir à une solution plus performante, fiable et pratique pour un usage réel. [?]

Bibliographie

1. <https://www.mdpi.com/2078-2489/15/9/517>.
2. https://d2l.ai/chapter_recurrent-modern/lstm.html.
3. https://www.researchgate.net/figure/TheArchitecture-of-the-gated-recurrent-unit-GRU-cell_fig2_370683092.
4. https://n8n.io/partnerkey=ZWFiZDIyYjkwZTFldps_xid=maX0KvyVauBXiigs_xid=maX0KvyVauBXiigspk=ZWFiZDIyYjkwZTFldgad_source=1.